

Directives & Cahier des Charges du Mini-Projet

Cours de Data Mining (Fouille de Données)

Année Académique : 2026/2027

EN BREF — RÈGLES ET MODALITÉS DU PROJET

- **Taille des Équipes** : De **3 étudiants minimum** à **6 étudiants maximum** par groupe.
- **Taille du Jeu de Données** : **Minimum 10 000 échantillons** ($\geq 10\,000$ lignes).
- **Domaine applicatif** : Libre choix (Santé, Finance, E-commerce, Vision, NLP, Énergie, etc.).
- **Parcours Technique** : Au choix entre **Classification Supervisée** OU **Clustering Non Supervisé** (ou Approche Hybride).
- **Livrable Applicatif** : Une application fonctionnelle et interactive (Web App Streamlit/Gradio/Flask, Desktop PyQt/Tkinter, ou Mobile App).
- **Modalités de Rendu** : **Pas de soutenance orale**. Évaluation uniquement sur le **Rapport PDF** (docs/Rapport_MiniProject.pdf) et le **Dépôt GitHub complet** (Code, Application, et README.md très détaillé).
- **Hébergement Git & Traçabilité** : Dépôt GitHub public obligatoire. **Historique des commits analysé individuellement**. Une absence de contributions Git personnelles entraînera une **pénalité lourde (note nulle)**.
- **Date Limite** : À la fin du semestre.

1. Objectifs et Philosophie du Mini-Projet

Le mini-projet constitue le pilier pratique du cours de **Data Mining**. Son objectif est de placer les étudiants dans la posture d'ingénieurs et de Data Scientists confrontés à un problème du monde réel.

Chaque équipe devra réaliser l'intégralité de la chaîne de traitement de données (*End-to-End Data Pipeline*), depuis la collecte et le prétraitement des données brutes jusqu'au déploiement d'une application décisionnelle interactive intégrant les algorithmes découverts en cours.

2. Organisation des Équipes et Suivi Git Strict

2.1. Composition des Groupes

- Les projets doivent être réalisés en équipes constituées de **3 étudiants au minimum** et **6 étudiants au maximum**.
- Aucun projet individuel ou en binôme ne sera accepté sans dérogation exceptionnelle accordée par l'enseignant.

2.2. Gestion de Version et Politique Git Obligatoire

ATTENTION — POLITIQUE DE TRAÇABILITÉ GIT STRICTE

1. Le projet doit être intégralement hébergé sur un dépôt **GitHub public**.
2. **Chaque membre du groupe doit posséder son propre compte GitHub** et contribuer activement par des commits réguliers, des branches explicites et des Pull Requests.
3. L'évaluation de l'implication individuelle sera effectuée via l'analyse des statistiques Git (*Git Commit History*, *Lines added/deleted*, *Pull Requests merged*).
4. **Pénalité Sanction** : Si un étudiant présente un historique Git vierge ou symbolique (ex: 1 unique commit la veille du rendu), **une note de zéro (0/20) lui sera attribuée à titre individuel**, quelle que soit la qualité globale du projet du groupe.

2.3. Règle d'Anonymisation sur les Supports Publics

CONFIDENTIALITÉ ET ANONYMAT SUR LES SUPPORTS PUBLICS

Dans l'ensemble des données et documents publics (**Dépôt GitHub**, **README.md**, **Notebooks**, **Code source** et **Rapport PDF**), **il est strictement interdit de mentionner les noms et prénoms réels des étudiants**.

- Seul le **code de l'étudiant** doit être utilisé.
- **Format du Code Étudiant** : Spécialité + Numéro d'ordre dans la liste du groupe (exemple : IASD01, IASD02, IASD03 pour le 3ème membre du groupe de la spécialité IASD).

2.4. Politique d'Utilisation des Outils d'IA et Responsabilité Académique

POLITIQUE D'USAGE DES OUTILS D'IA ET AUDIT D'AUTHENTICITÉ

1. **Usage Autorisé** : L'utilisation des assistants d'Intelligence Artificielle (ex : ChatGPT, Claude, Gemini, GitHub Copilot) est **autorisée** pour assister la rédaction, la recherche documentaire et le débogage de code.
2. **Responsabilité Pédagogique Totale** : Les étudiants demeurent **100% responsables** de l'exactitude scientifique, de la rigueur mathématique et de la validité de toutes les informations, formules et lignes de code fournies ou générées par des outils d'IA.
3. **Convocation à une Audition Orale d'Évaluation** : En cas de suspicion d'utilisation d'IA sans vérification préalable (ex : concepts hallucinés, réponses incohérentes ou code non maîtrisé), **les étudiants concernés pourront être convoqués individuellement à une audition orale d'évaluation**. L'étudiant devra répondre en détail à toutes les questions techniques sur son projet, son code et son rapport. Une incapacité à expliquer le travail entraînera des pénalités individuelles lourdes.

3. Exigences sur le Jeu de Données et le Domaine Applicatif

3.1. Choix du Domaine Applicatif

Le choix du domaine métier est totalement libre afin de permettre à chaque groupe de travailler sur une thématique passionnante. Exemples de domaines éligibles :

- **Finance & Banque** : Détection de fraudes par carte de crédit, scoring de crédit, prédiction du churn client.
- **Santé & Bioinformatique** : Diagnostic médical assisté, prédiction de maladies cardiaques/diabète, génomique.
- **E-commerce & Marketing** : Système de recommandation, segmentation d'acheteurs, analyse de sentiment des avis.
- **Transport & Smart Cities** : Prédiction de congestion routière, optimisation de flottes, consommation énergétique.
- **Traitement d'Images / NLP** : Classification de documents textuels, reconnaissance d'objets ou de signaux.

3.2. Volumétrie des Données

- Le dataset choisi doit comporter au **strict minimum 10 000 lignes** ($\geq 10\,000$ enregistrements).
- Le dataset doit contenir au minimum 8 à 10 attributs (numériques, catégoriels ou textuels) permettant de justifier des prétraitements et analyses complexes.
- Sources recommandées : Kaggle, UCI Machine Learning Repository, Google Dataset Search, data.gov, OpenData.

4. Parcours Techniques et Algorithmes du Cours

Chaque groupe doit choisir l'un des deux parcours principaux (ou proposer une approche hybride combinant les deux) :

PARCOURS A : CLASSIFICATION SUPERVISÉE

Si vous choisissez la classification supervisée, vous devez obligatoirement implémenter et comparer les algorithmes suivants :

1. **Classifieur de Référence (Baseline)** : Classifieur Naïf / Zero-R.
2. **K-Nearest Neighbors (K-NN)** : Étude de l'impact du paramètre K , des métriques de distance (Euclidienne, Manhattan) et de la standardisation des variables.
3. **Arbres de Décision & Random Forest** : Analyse du gain d'information (Entropie), Indice de Gini, élagage (*cost-complexity pruning*), et importance des variables.
4. **Classifieur Naïve Bayes** : Application de GaussianNB, MultinomialNB ou BernoulliNB avec gestion du lissage de Laplace.
5. **Support Vector Machines (SVM)** : Évaluation des noyaux (Linéaire, RBF, Polynomial) et réglage des hyperparamètres C et γ .

Évaluation : Matrice de confusion, Accuracy, Précision, Rappel, F1-Score, Courbe ROC-AUC et validation croisée (K -fold Cross Validation).

PARCOURS B : CLUSTERING NON SUPERVISÉ

Si vous choisissez le clustering non supervisé, vous devez obligatoirement implémenter et comparer les familles suivantes :

1. Méthodes de Partitionnement :

- **K-Means** : Recherche du K optimal via la méthode du coude (*Elbow Method*) et l'initialisation K -Means++.
- **K-Medoids (PAM)** : Comparaison de la robustesse aux valeurs aberrantes par rapport à K -Means.

2. Méthodes Hiérarchiques :

- **AGNES (Agglomératif)** : Construction et analyse des dendrogrammes avec critères de liaison (Ward, Complete, Single, Average).
- **DIANA (Divisif)** : Analyse top-down de la séparation des clusters.

Évaluation : Métriques internes (Score de Silhouette $s(i)$, Indice de Davies-Bouldin DBI , Indice de Dunn) et métriques externes si une vérité terrain existe (Rand Index RI , ARI , NMI). Visualisation 2D/3D via PCA.

5. Développement de l'Application Interactive

Le projet ne doit pas se limiter à des scripts Python ou des notebooks Jupyter. Chaque groupe doit développer une **application utilisateur fonctionnelle et déployée** :

- **Applications Web (Recommandé)** : Réalisées avec **Streamlit**, **Gradio**, **Dash** ou **Flask/React**.
- **Applications Desktop / Mobile** : Réalisées avec **PyQt**, **Tkinter**, **Kivy** ou **Flutter**.

Fonctionnalités minimales attendues dans l'application :

1. **Dashboard d'Exploration (EDA)** : Visualisation interactive des données, graphiques de distribution, matrice de corrélation.
2. **Module de Prédiction / Clustering en Temps Réel** : Formulaire permettant à un utilisateur d'aisément saisir de nouvelles valeurs et d'obtenir instantanément la classe prédite ou le cluster d'appartenance avec la probabilité/confiance associée.
3. **Comparateur de Modèles** : Affichage interactif des tableaux comparatifs de performances et des graphiques de métriques.

6. Structure Obligatoire du Dépôt GitHub & Contenu du README.md

6.1. Arborescence Standardisée du Projet

Chaque équipe doit respecter la structure de projet standardisée suivante dans son dépôt GitHub :

```
nom-du-projet-datamining/
|-- README.md           # Documentation principale (Instructions, Rôles, Objectifs, Rés
|-- data/
|   |-- raw/             # Données brutes (ou lien de téléchargement si > 100 Mo)
|   |-- processed/       # Données nettoyées et transformées
|-- notebooks/          # Notebooks Jupyter structurés étape par étape
|   |-- 01_eda_and_cleaning.ipynb
```

```
| |-- 02_preprocessing_encoding.ipynb
| '-- 03_model_training_evaluation.ipynb
|-- src/                                # Code source Python complet de l'application
| |-- app.py                            # Point d'entrée principal de l'application (ex: Streamlit)
| |-- preprocessing.py                  # Fonctions de nettoyage et préparation
| '-- models.py                        # Chargement des modèles et fonctions de prédiction
|-- docs/                              # Rapport scientifique complet au format PDF
| '-- Rapport_MiniProject.pdf
'-- requirements.txt                    # Liste exacte des dépendances Python (pandas, scikit-learn, et
```

6.2. Contenu Exigé du Fichier README.md sur GitHub

Le fichier README.md constitue le **rapport GitHub principal** de votre projet. Il doit obligatoirement inclure les 4 sections suivantes :

SECTION 1 : Présentation, Objectifs et Description du Projet

- Titre clair du projet et contexte métier.
- Description détaillée des objectifs scientifiques et applicatifs.
- Présentation du dataset (source, nombre d'échantillons $\geq 10\,000$, attributs clés).

SECTION 2 : Guide d'Installation et Lancement de l'Application

- Instructions étape par étape pour cloner le dépôt, installer les dépendances et exécuter l'application interactive localement. Exemple :

```
git clone https://github.com/votre-equipe/nom-du-projet.git
cd nom-du-projet
python -m venv venv && source venv/bin/activate # ou venv\Scripts\activate sous Windows
pip install -r requirements.txt
streamlit run src/app.py
```

- URL de déploiement en ligne le cas échéant (ex: Streamlit Community Cloud, Hugging Face Spaces).

SECTION 3 : Rôles des Membres et Matrice des Contributions

Tableau explicite détaillant les responsabilités exactes de chaque étudiant (**Règle d'anonymat** : utiliser uniquement le Code Étudiant, aucun Nom/Prénom réel) :

Étudiant (Code Étudiant)	Identifiant GitHub	Rôle & Contributions Principales
IASD01	@github_id1	EDA, Nettoyage des données, Implémentation K-NN & SVM.
IASD02	@github_id2	Arbres de Décision, Random Forest, Tuning d'hyperparamètres.
IASD03	@github_id3	Développement de l'Interface Web Streamlit & Déploiement.

SECTION 4 : Résultats Clés et Synthèse des Découvertes

- Tableau synthétique comparant les performances de tous les modèles testés (Accuracy, F1-Score, ROC-AUC ou Silhouette, DBI).
- Analyse critique du meilleur modèle retenu et principales conclusions métiers (*Key Findings*).

7. Grille d'Évaluation Hyper-Détaillée (Barème sur 20 Points)

L'évaluation repose sur un barème analytique sous-fractionné sur **20.0 Points**, évaluant chaque sous-élément technique du projet :

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
PARTIE 1 : RIGUEUR TECHNIQUE & DATA MINING (TOTAL : 10.0 POINTS)		
1.1 Prétraitement des Données	Nettoyage des valeurs manquantes/aberrantes, encodage des variables catégoriques (One-Hot/Label/Binary), normalisation/standardisation (Z-score/Min-Max/Robust Scaling).	2.0 pts
1.2 Analyse Exploratoire (EDA) & Tests Statistiques	Visualisations des distributions, matrices de corrélation, et réalisation obligatoire de tests statistiques (ex: χ^2 , ANOVA, test de Student, test de normalité Shapiro-Wilk, corrélations de Pearson/Spearman).	3.0 pts
1.3 Implémentation des Modèles du Cours	Implémentation et comparaison rigoureuse de TOUS les algorithmes requis du cours selon le parcours choisi (Zero-R, K-NN, Arbres/Random Forest, Naïve Bayes, SVM <i>OU</i> K-Means, K-Medoids, AGNES, DIANA).	1.0 pt
1.4 Optimization & Cross-Validation	Réglage méthodique des hyperparamètres (Grid-Search / RandomSearch) et évaluation par validation croisée (<i>K</i> -Fold Cross Validation, $K \geq 5$).	2.0 pts
1.5 Analyse des Métriques Comparatives	Tableau comparatif multicritère complet, matrices de confusion, courbes ROC-AUC, Precision/Recall/F1-Score (ou Silhouette $s(i)$, Davies-Bouldin <i>DBI</i> , Rand Index <i>RI</i>).	2.0 pts
PARTIE 2 : APPLICATION INTERACTIVE & ERGONOMIE (TOTAL : 4.0 POINTS)		
2.1 Architecture & Stabilité UI	Application fonctionnelle (Streamlit, Gradio, Web/Desktop), absence de bugs au runtime, code propre et modulaire dans <code>src/app.py</code> .	1.5 pts
2.2 Dashboard EDA Interactif	Composant d'exploration dynamique permettant à l'utilisateur de filtrer les données et visualiser interactivement les graphiques.	1.0 pt
2.3 Prédiction / Clustering Temps Réel	Formulaire interactif de saisie dynamique des valeurs d'entrée générant des prédictions/clustings instantanés avec probabilité/confiance.	1.5 pts
PARTIE 3 : TRAÇABILITÉ GIT & COMMITS INDIVIDUELS (TOTAL : 3.0 POINTS)		
3.1 Discipline & Structure du Dépôt	Respect strict de l'arborescence recommandée (<code>data/</code> , <code>notebooks/</code> , <code>src/</code> , <code>docs/</code>), présence du fichier <code>requirements.txt</code> et clarté des messages de commit.	1.0 pt
3.2 Commits & Contributions Individuelles	Régularité des commits personnels par étudiant sur GitHub, équité de la participation. Note : Pénalité de 0/20 attribuée individuellement si l'historique d'un membre est vierge.	2.0 pts
PARTIE 4 : RAPPORT PDF & DOCUMENTATION GITHUB (TOTAL : 3.0 POINTS)		

Catégorie / Sous-Critère	Critères de Notation et Exigences Techniques	Points
4.1 Rapport Scientifique PDF	Rapport académique rédigé dans docs/Rapport_MiniProject.pdf (Problématique, méthodologie, justifications théoriques des algorithmes, interprétation des résultats).	1.5 pts
4.2 Documentation README.md GitHub	Fichier README.md exemplaire incluant la présentation, le guide d'installation/lancement pas-à-pas, la matrice des rôles/contributions nominative et la synthèse des résultats clés.	1.5 pts
TOTAL GÉNÉRAL	Évaluation Finale du Mini-Projet (Sans Soutenance Orale)	20.0 pts

8. Jalons et Date Limite de Rendu

- **Jalon 1 (Semaine 4) :** Constitution des groupes (3 à 6 étudiants), choix du domaine applicatif, sélection du dataset ($\geq 10\,000$ lignes) et création du dépôt GitHub.
- **Jalon 2 (Semaine 8) :** Rendu du notebook d'EDA et de prétraitement des données.
- **Jalon 3 (Semaine 12) :** Implémentation des modèles de Data Mining et validation croisée.
- **Rendu Final (Fin du Semestre) :** Soumission de l'URL du dépôt GitHub public contenant le code, l'application fonctionnelle, le rapport PDF et le README.md complet.

Bon travail à toutes les équipes !